视觉语言导航
第一章、基础介绍

主 讲：Conner QIU

公众号：具身智能之心

主要内容

1. 主讲人介绍
2. VLN为什么重要?
3. VLN任务有什么特点?
4. VLN算法的范式是什么?

01

主讲人介绍

自我介绍

Conner QIU：

- 本科就读于中山大学
- 硕士与博士就读于香港科技大学（广州）
- 主要研究方向：具身智能中的导航问题，移动抓取
- 机器人创始公司合伙人
- 其他领域：中国注册会计师，持有中国法律职业资格证，

具身智能之心

打造行业领先的技术与产业交流平台

公众号

干货每日放送

B站

不定期直播+最新视频

知识星球

海量图文教程和PAPER分享

视频号

技术视频一站式分享

02

VLN为什么重要?

具身智能背景下的VLN

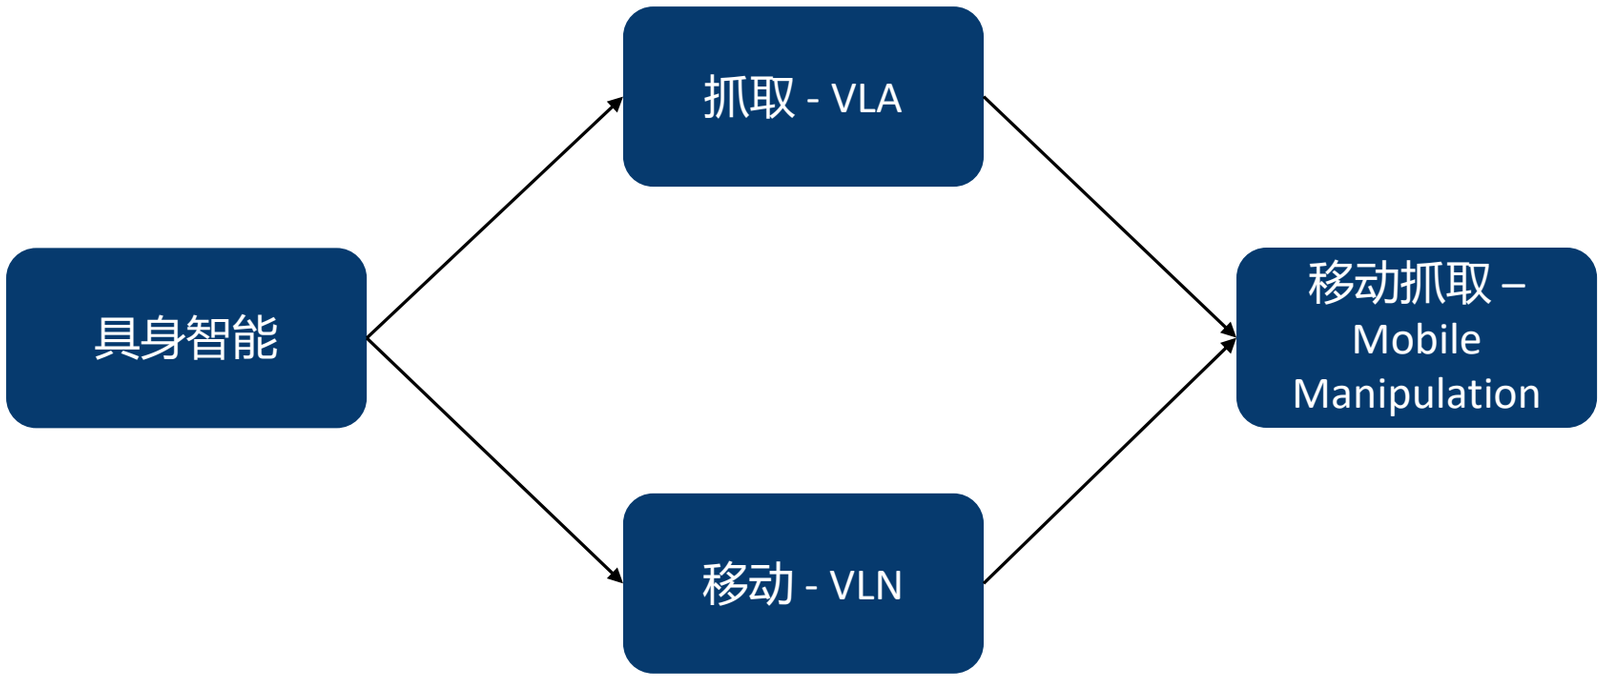

- 抓取解决机器人“手”相关的问题，移动解决机器人“脚”相关的问题。
- 抓取和移动面临着相似的挑战，长时序的推理问题，陌生环境的泛化性，视觉语言对齐…
- 移动抓取问题结合了抓取与移动，目前已有的探索较少，会是下一阶段的热点。

视觉语言导航（VLN）就是为了研究机器人基于人类指令的移动问题

视觉语言导航与传统导航问题的区别

属性	传统导航	视觉语言导航
地图形式	预建图/SLAM建图	无图端到端模型/语义图
环境类型	已知和结构化环境	未见和动态环境
目标定义	静态目标点	语言描述的动态目标
任务复杂性	不涉及多模态信息融合	结合视觉、语言和动作推理
适用场景	自动驾驶、室外导航	服务机器人、室内任务

- 传统导航着重从空间信息上解决问题，
  - 依据深度、雷达、里程计信息建立地图，形成机器人对环境的几何理解
  - 对于目标的描述是空间中的点坐标
- 视觉语言导航关注语义信息上的问题：
  - 直接采用无图的端到端模型或者构建语义拓扑图作为机器人对环境的语义理解
  - 目标是通过语言来描述的，强调视觉和语言信息的交互

视觉语言导航的业界现状

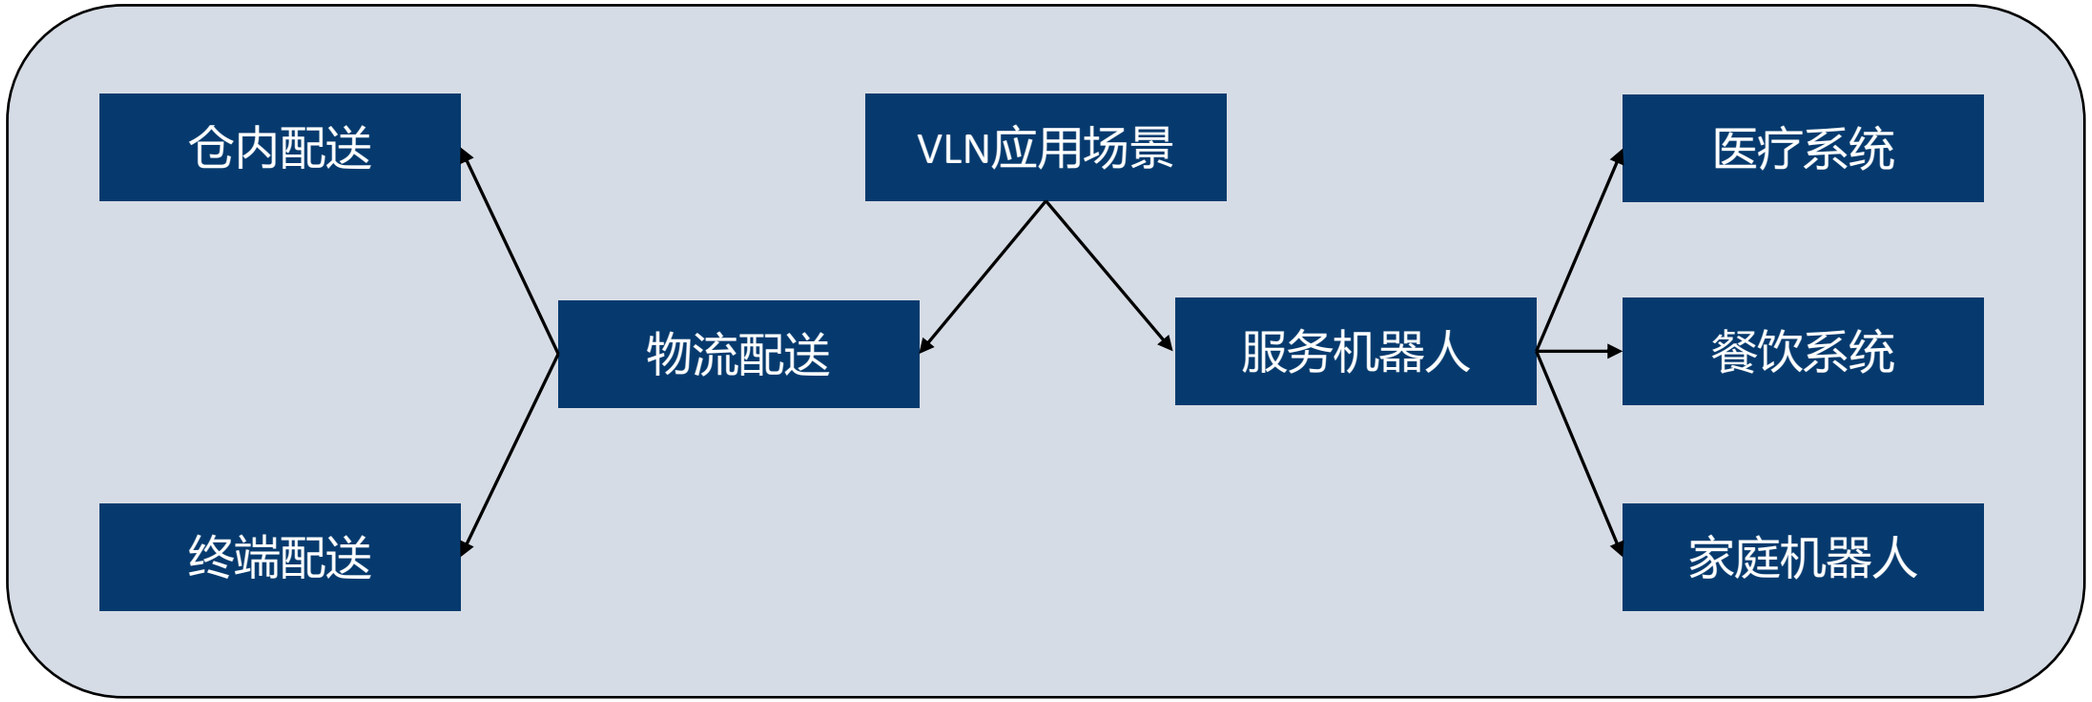

具身智能之心

03 VLN任务有什么特点?

这门课程讨论的VLN

任务定义：

给定一个描述目标或路径的语言指令，机器人在一个陌生的环境里，根据环境中的视觉信息导航到目的位置。

核心拆解：

- V：视觉信息的格式可以为单目视觉照片或者360度照片
- L：语言指令可以描述一条路径或者一个目标，语言指令可以精细或者简洁（模糊）
- N：机器人无法预先得知环境的空间或语义信息，它需要探索环境以获得对环境的理解

怎么开展VLN研究?

研究的两个阶段：

- 训练，主要考虑数据来源，监督信号的获取。
  - 离线数据集
  - 仿真环境
- 测试，考虑评测标准，如果在对比不同方法的效果。
  - 实机测试： 解决Sim-to-real Gap，需要复现对比的方法，难以建立统一评测标准
  - 仿真环境评测：统一评测标准，轻松对比不同方法，方法迁移到实机的效果难以保证。

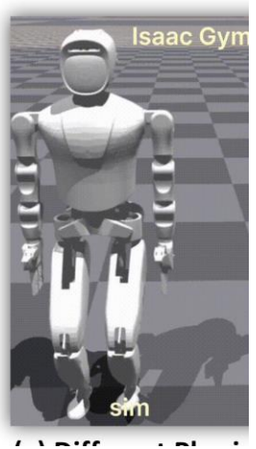

仿真？

实机？

VLN最初在仿真中开展研究

导航任务三个要素：

1. **场景**
    1. 室内/室外
    2. 3D场景数据集，与模拟器需要互相匹配

2. **任务**
    1. 目标描述：如何描述任务？ 例子：“帮我找一个玻璃杯”
    2. 初始状态：如何采样出合理的初始状态？
    3. 成功状态：如何判定成功与失败？ 如何评价机器人的表现？

3. **机器人 Agent**
    1. 构型：四足，人形，轮式
    2. 动作空间：离散/连续，轨迹控制/速度方向
    3. 传感器：RGB，Depth，Lidar

VLN的场景 – 聚焦室内场景

3D场景数据集 ⟷ 模拟器

Matterport3D: Learning from RGB-D Data in Indoor Environments

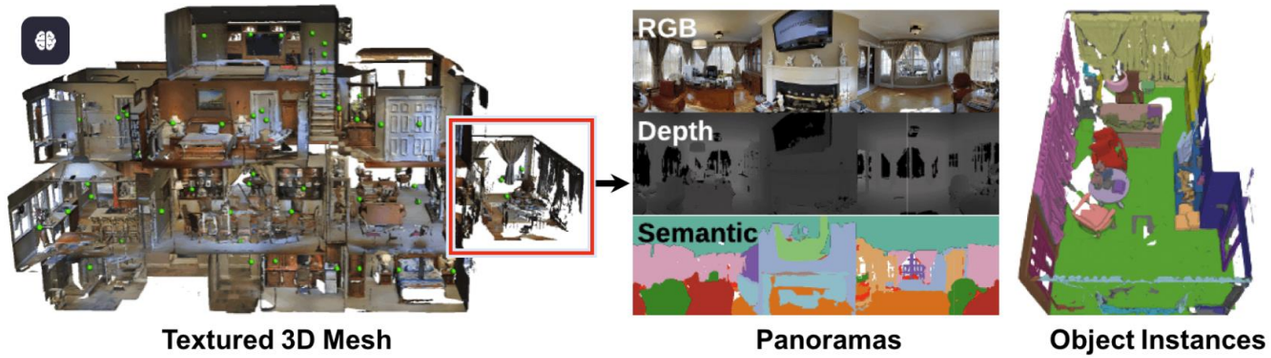

MP3D

Habitat

Issac Gym

Habitat Matterport Dataset

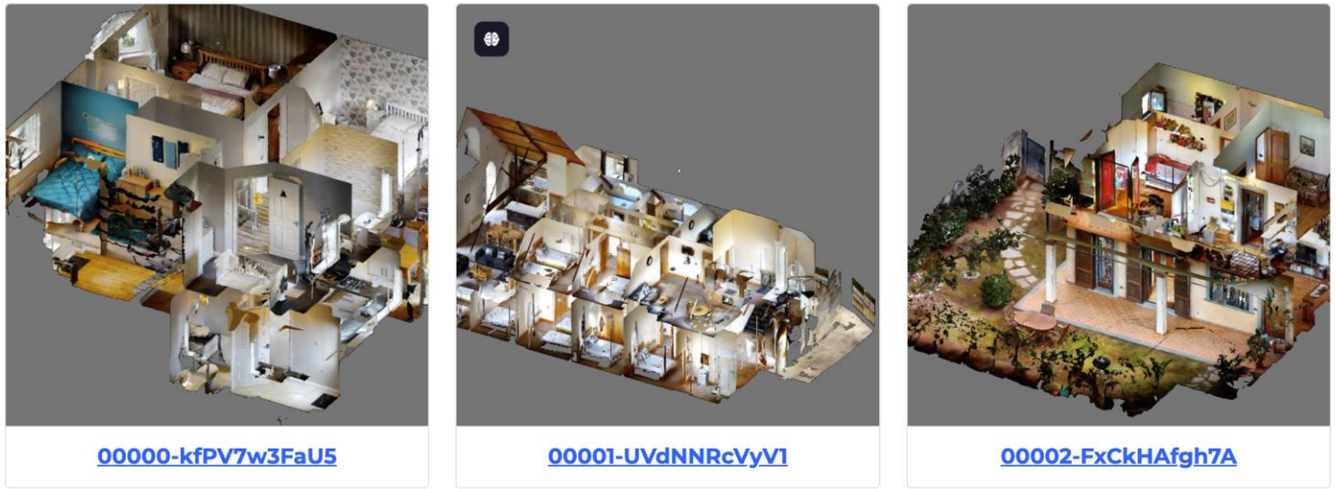

具身智能之心

VLN的任务 – 以R2R为例

Walk toward the railing and right past the stairs. Walk into the living room and turn right. Stop by the end table.

任务描述：一段描述路径的文字，限定了途径点，以及结束的位置。

起始条件： 机器人预先不知道环境的任何信息，从描述的起点出发。

成功条件：机器人到目标点，做出结束动作，即为成功。

导航任务有各种不同的Benchmark，第二章将会进行详细介绍。

VLN的Agent – 以R2R为例

构型：虚拟的Agent

观测空间：360° RGB 图像，深度图像

动作空间：前进，左转，右转，停止

Agent在空间里遵循预定义的拓扑图运动

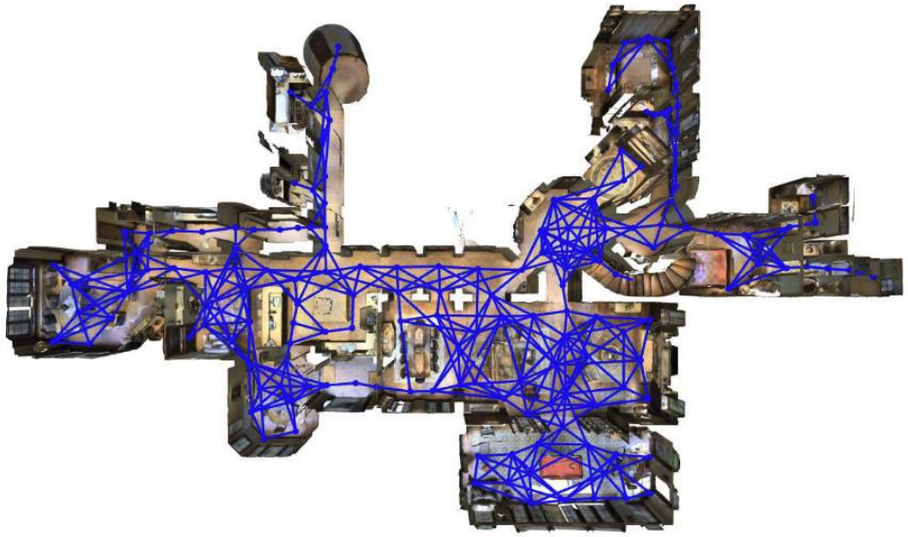

用人类的视角来完成一次VLN任务

Walk beside the outside doors and behind the chairs across the room.

Turn right and walk up the stairs. Stop on the seventh step.

VLN的任务特点

VLN的任务性质

- 视觉的理解、语言的理解、视觉与语言的匹配（对于人类来说，非常简单）
- 记忆历史信息，走过了哪些地方
- 预测动作的结果，预测未来信息
- 执行正确的导航动作

VLN的挑战

- 编码视觉信息，构建环境的表征
- 编码语言信息，与视觉信息交互
- 训练场景，训练数据的有限性
- 泛化到新的场景

算法如何学习？

模仿学习

- 需要示范数据：最短路径，人类标注
- 监督信号：是否和示范路径一致
- 训练速度快
- 存在错误的累积风险

强化学习

- 通过与环境的交互来学习，获取奖励
- 监督信号：奖励的最大化。 巴普洛夫的狗
- 数据效率低
- 可以学习自我纠正

04

VLN算法的范式是什么?

VLN算法的范式

目前VLN算法的根本驱动来自于应对数据的匮乏
VLN 是一个 多模态的时序决策问题

?

- 理解这个范式，你会发现VLN各种论文的算法，创新点，都在这个框架之下
- 课程的内容也依据这个框架进行展开
- 解决看过很多论文，却依然无法形成系统性认知的痛点
- 再阅读新论文时，可以迅速对其进行归类
- 帮助你认识到领域内未解决的问题，构建自己的创新点

课程希望达到的效果

- 传授思维框架，不仅仅是零碎的算法知识
- 对领域形成系统性认知，看清领域如何而来，将向哪里发展
- 理论与实践结合，Make your hands dirty